

# 基于卡尔曼滤波的电力系统短期负荷预测

## Short-term Load Forecasting for Power Systems Based on Kalman Filter

**ABSTRACT:** The magnitude of power load is closely related to weather factors. Therefore, it is conducive to obtain more accurate forecasting results considering weather factors. Based on the Kalman filter algorithm, this paper considered the influence of weather on short-term load prediction of power system. The algorithm first built the load demand model; then the hourly load data on the forecast day was recursively estimated by Kalman filter, using the historical load data and weather data near the day to be forecast. The simulation results showed that the load forecast results after considering weather factors are more accurate.

**KEY WORDS:** Kalman filter; short-term load forecasting; power system

**摘要:** 用电负荷的大小与天气因素息息相关,所以考虑天气因素有利于负荷预测得到更为准确的结果。基于卡尔曼滤波算法,本文考虑了天气因素对电力系统短期负荷预测带来的精度影响。该算法首先建立负荷需求模型,然后利用待预测天邻近的历史负载数据和天气数据,用卡尔曼滤波递归估计待预测天每小时的用电负荷。仿真结果表明,考虑天气因素后的负荷预测结果更为准确。

**关键词:** 卡尔曼滤波; 短期负荷预测; 电力系统

## 0 引言

电力系统短期负荷预测指考虑系统运行特性、增容决策与自然条件,对历史负荷数据处理,对未来几周、几天、几小时的需求量进行预测的过程。它是电网经济运行的主要依据,是电网可靠运行的保证,是安排开停机计划的基础,也对电网调度自动控制非常重要,对电力市场化下的电力系统的经济效益有重要影响。

目前负荷预测的研究方法有回归分析法<sup>[1]</sup>、时间序列法<sup>[2]</sup>、卡尔曼滤波法、专家系统法<sup>[3]</sup>、神经网络法<sup>[4]</sup>等。其中回归分析法、时间序列法比较传统简单,但适用范围小、预测精度低;近些年发展的专家系统法、神经网络法预测精度高,但有工作量大、学习时间长的缺陷。

卡尔曼滤波(KF)由 Kalman 于 1960 年提出。

该方法采用状态方程和观测方程组成的线性随机系统的状态空间模型来描述滤波器,以随机信号为处理对象,利用系统噪声和观测噪声的统计特性,按线性无偏最小均方差估计准则,以系统的观测量作为滤波器的输入,采用递推算法对所要得到的估计值(系统的状态)进行最佳估计,得到输出。

将卡尔曼滤波用于短期负荷预测在国外已有研究, M. Huelsemann, M. D. Seiser 等人在 1998 年就尝试将卡尔曼滤波算法和自相关性运用于负荷预测领域<sup>[5]</sup>,提出用卡尔曼滤波进行负荷预测的思路,取得理论上的突破。文献[6]建立了新颖的考虑时变天气的负荷模型,利用卡尔曼滤波对负荷模型的系数进行估计,即通过状态方程和输出方程建立了负荷模型。

该法既可以对平稳的一维随机过程进行估计,也可以对非平稳的、多维随机过程进行估计,适用对象广泛。且其核心公式简洁,使用成熟,因而适合用于短期负荷预测。

本文首先利用卡尔曼滤波理论构建了考虑局部天气因素的电力系统短期负荷预测算法;然后利用某公司的历史负荷数据和相关历史气象数据等,进行了为期 24h 的短期负荷预测,验证了该预测模型的可行性与有效性。

## 1 算法简介与短期负荷预测方法的实现思路

### 1.1 算法简介

考虑离散线性系统表示如下:

$$x(t+1) = \Phi(t+1, t)x(t) + B(t)\omega(t) \quad (1)$$

$$y(t) = H(t)x(t) + v(t) \quad (2)$$

式中:  $x$  是  $n$  维状态变量,  $T(t+1, t)$  是  $n \times n$  的状态转移矩阵,  $B(t)$  是  $n \times r$  的输入噪声转移矩阵,  $\omega(t)$  是  $p$  维的输入噪声;  $y(t)$  是  $m$  维的测量向量,  $H(t)$  是  $m \times n$  维测量矩阵,  $v(t)$  是  $m$  维的测量噪声。假设输入噪声  $\omega(t)$  与测量噪声  $v(t)$  是互不相关、均

值为零的独立白噪声, 其统计特性如下:

$$\begin{aligned} E\omega(t) &= 0, E\omega(t)\omega^T(t) = \mathbf{Q}; \\ Ev(t) &= 0, Ev(t)v^T(t) = \mathbf{R}(t); \\ E\omega(t)v^T(k) &= 0; \end{aligned}$$

其中:  $E$  表示数学期望;  $\mathbf{Q}(t)$  是对称正定的  $p \times p$  阶的输入噪声协方差阵;  $\mathbf{R}(t)$  是对称正定的  $m \times m$  阶的测量噪声协方差阵。

又设初始状态  $x(0)$  独立于  $\omega(t)$  和  $v(t)$ , 且已知其统计特性为:

$$E[x(0)] = \mu_0, E[(x(0) - \mu_0)(x(0) - \mu_0)^T] = P_0;$$

记  $x(t+1|t)$  为  $(t+1)$  时刻的  $x(t+1)$  的先验估计值。假设已求得状态  $x(t)$  的最优滤波估计  $\hat{x}(t)$ 。在  $(t+1)$  时刻的测量值获取之前, 由于  $\omega(t)$  是不可预测的白噪声序列, 根据已有的测量信息只能用下式作  $x(k+1)$  的先验估计:  $\hat{x}(t+1|t) = \Phi(t+1)\hat{x}(t)$ 。

对测量信号  $y(t+1)$  的预测估计为:  $\hat{y}(t+1) = H(t+1)\hat{x}(t+1|t)$ 。

估计值  $\hat{x}(t+1|t)$  是不考虑  $\omega(t)$  影响的近似估计值, 其误差协方差阵为:

$$\hat{P}(t+1) = E[(x(t+1) - \hat{x}(t+1))(x(t+1) - \hat{x}(t+1))^T]$$

于是根据观测向量  $y(t+1)$  与  $H(t+1)\hat{x}(t+1|t)$  之差来修正这个估计值, 以得到最优滤波估计, 为此在  $y(t+1) - H(t+1)\hat{x}(t+1|t)$  之前乘以一个系数  $K(t+1)$ , 即:

$$\hat{x}(t+1) = \hat{x}(t+1|t) + K(t+1)[y(t+1) - H(t+1)\hat{x}(t+1|t)]$$

式中:  $K$  为卡尔曼增益,  $K$  必须使均方误差  $P(t+1)$  为最小, 即  $\text{Tr}[P(t+1)] = \min$ , 由均方误差最小可以推得:

$$K(t+1) = P(t+1|t)H^T(t+1)[H(t+1)P(t+1|t)H^T(t+1) + R(t+1)]^{-1}$$

由此得到卡尔曼滤波的递推方程组如下:

$$\hat{x}(t+1|t) = \Phi(t+1)\hat{x}(t) \quad (3)$$

$$\hat{x}(t+1) = \hat{x}(t+1|t) + K(t+1)[y(t+1) - H(t+1)\hat{x}(t+1|t)] \quad (4)$$

$$K(t+1) = P(t+1|t)H^T(t+1)[H(t+1)P(t+1|t)H^T(t+1) + R(t+1)]^{-1} \quad (5)$$

$$P(t+1|t) = \Phi(t+1)P(t)\Phi^T(t+1|t) + Q(t) \quad (6)$$

详细推导过程见文献[7]。可以看到, 卡尔曼

滤波具有两个互相影响的计算回路: 状态更新回路和量测更新回路, 也就是预测与校正的过程。

以连续若干天的同一时刻作为一组时间序列预测该时刻的下一个负荷值, 建立负荷模型如下, 负荷被分为四个部分:

$$L_k(t) = H_{Nk}(t)L_{Nk}(t) + H_{Pk}(t)L_{Pk}(t) + H_{Tk}(t)L_{Tk}(t) + v_k(t) \quad (7)$$

式中:  $L_k(t)$  为第  $t$  天第  $k$  时刻负荷值  $L_{Nk}(t)$  为该时刻的基本负荷,  $L_{Pk}(t)$  为前一天同时刻的负荷,  $L_{Tk}(t)$  为该时刻的气温,  $v_k(t)$  为误差,  $H_{Nk}(t)$ 、 $H_{Pk}(t)$ 、 $H_{Tk}(t)$  均为参数矩阵。由于预测的是某个时刻的值, 所以式中的各个量都是一维的。为方便应用卡尔曼滤波理论进行状态预测, 特作如下变换:

$$\begin{aligned} y_k(t) &= L_k(t) \\ H_k(t) &= [H_{Nk}(t), H_{Pk}(t), H_{Tk}(t)] \\ x_k(t) &= [L_{Nk}(t), L_{Pk}(t), L_{Tk}(t)]^T \end{aligned}$$

从而关于负荷的系统方程与观测方程为:

$$x_k(t) = \Phi_k(t)x_k(t-1) + \omega_k(t) \quad (8)$$

$$y_k(t) = H_k(t)x_k(t) + v_k(t) \quad (9)$$

式中:  $y_k(t)$  是观测值,  $H_k(t)$  为观测矩阵,  $\Phi_k(t)$  为状态转移矩阵,  $\omega_k(t)$  为状态误差。

预测方程为:

$$y_k(t+1|t) = H_k(t+1)x_k(t+1|t) \quad (10)$$

此方程与式(3), (4), (5), (6)构成了一套卡尔曼滤波负荷预测递推方程组。

又用电负荷的历史数据也体现了随气候变化而变化的特性, 而负荷受气候的影响一般在几个月或几年的长期时间维度会比较明显, 几小时或一两天的短期气候影响一般并不突出, 从而气候变化对负荷预测的影响主要表现在温度改变引起的负荷变化上。

由于实际预测过程中有预测时刻的气温预报值, 可以对负荷预测值进行温度的修正[8]。

设待预测的第  $(t+1)$  天  $k$  时刻负荷的卡尔曼滤波预测值为  $y_k(t+1|t)$ , 该时刻的状态估计值为  $L_{Tk}(t+1|t)$ , 而该预测时刻的气温预报值为  $T_k$ 。状态估计值是卡尔曼滤波器通过历史负荷得到的对系统下一个时刻状态的最佳估计, 而预报获得的系统的新的状态值则反映了系统的未来状态, 因此他们的组合能够让预测模型获得更多的信息, 从而得到更加准确的预测值。对预测得到的值进

行修正, 有:

$$y_k(t+1) = y_k(t+1|t) + b_k[T_k - L_{tk}(t+1|t)] \quad (11)$$

式中:  $b_k$  为修正系数, 可以通过试验获得,  $y_k(t+1)$  为该时刻修正后的负荷预测值。

## 1.2 实现思路

由于测量不准、人为错录等因素会影响历史数据的准确性, 从而严重影响预测结果, 首先对初始的负荷历史数据进行预处理。

根据电力系统历史负荷数据的周期性, 本文认为每日同一时刻的负荷波动不大, 即同时刻的负荷值维持在一定的范围内, 所以在进行负荷预测之前要对数据在一定范围内进行选择 and 修正。

修正方法如下: 设负荷历史数据为  $x_1, \dots, x_n$ ,

取平均值  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ , 若  $x_i > \bar{x}(1+20\%)$ , 取  $x_i = \bar{x}(1+20\%)$ ; 若  $x_i < \bar{x}(1-20\%)$ , 取  $x_i = \bar{x}(1-20\%)$ 。

数据预处理后, 得到迭代方程几个所需要的初值。由于在本文中状态变量是连续若干天的同一时刻的温度, 它在短期的负荷预测中可以看是缓变状态, 因此可令  $\Phi_k(t) = I$ ,  $I$  为单位阵。对于观测矩阵, 由于是同一个时刻, 所以负荷模型中的基本负荷可以看作不变, 因而可以令  $H_{Nk}(t) = 1$ , 而  $H_{Pk}(t), H_{Tk}(t)$  可以通过线性回归法拟合得到。

除此之外, 初始状态  $x_k(0|0) = 0$ , 对历史负荷数据进行协方差计算获得协方差矩阵的初值  $P_k(0|0) = P_0$ 。实际上, 实践中初始状态  $x_k(0|0)$  和  $P_k(0|0)$  很难准确掌握。但卡尔曼滤波算法在递推过程中会不断用新的信息对状态进行修正, 所以当滤波时间充分长时, 状态初值  $x_k(0|0)$  对  $x_k(t+1|t)$  的影响将衰减至近于零, 初始协方差阵  $P_k(0|0)$  对滤波估计协方差阵  $P_k(t+1|t)$  的影响也将衰减至近似于零。因此, 滤波的初始条件可以近似确定。

两个噪声协方差则经实验寻找得到合适值。其中  $R_k$  过大过小都会使滤波效果变差, 且当  $R_k$  取值越小卡尔曼滤波的收敛速度会越快。

初值选定后对三天、每天 24h 共 96 个时刻的负荷数据进行卡尔曼滤波的迭代处理, 输出第四天的负荷预测值。

最后根据当地预测日的气温预报值, 在已有的预测值基础上对温度部分进行修正。

## 2 算例分析

以美的暖通公司 2017 年 5 月 3 日到 5 月 5 日三日内的每小时电力负荷数据为基础, 通过卡尔曼滤波算法对 5 月 6 日每小时的电力负荷进行预测分析。

引入误差指标, 绝对误差为:

$$abserr = \frac{|第 i 小时预测值 - 第 i 小时实际值|}{第 i 小时实际值} \times 100\% \quad (12)$$

预测算法考虑温度因素前后所得预测值与实际值的对比图见图 1, 所得预测值的绝对误差如图 2 和图 3。

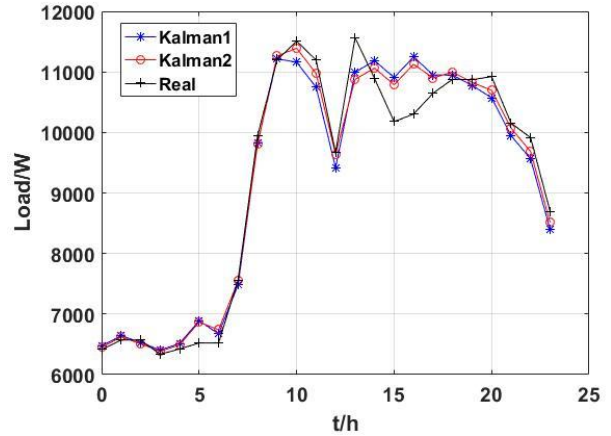


图 1 考虑温度因素前后的卡尔曼滤波日负荷预测

Fig.1 Kalman filter daily load prediction before and after considering temperature factor




图 2 卡尔曼滤波算法的绝对误差

Fig.2 Absolute error of Kalman filter




图 3 考虑温度因素的卡尔曼滤波算法的绝对误差

Fig.3 Absolute error of Kalman filter considering temperature factor

图 1 星号折线代表基本卡尔曼滤波算法所得预测值, 圆圈折线代表改进算法所得预测值, 可见在几个波峰、波谷处预测值相比实际值偏移较大, 改进算法的偏移程度相比基本算法有一定减小。

通过绝对误差量化分析, 由图 2 可知, 基本算法误差在波峰、波谷的 5h、11h、13h、15h、16h 等多个时刻超过 4%, 在 15、16h 的误差最大, 16h 误差达到 9%。算法改进后, 15、16h 误差均有所下降, 且多时刻误差普遍降至 2%以下。波峰波谷处, 10h-13h 的精度改进最为明显, 由基本算法的 5%上下降至 2%左右。可见, 改进算法有一定成效。

但图中所示, 5-6h、14h 误差改进并不明显, 认为此时温度预测已经准确, 其偏差主要来自负荷及系统过程的噪声, 所以针对温度的修正并不能提高预测准确度。

### 3 结论

本文建立了基于卡尔曼滤波理论的电力系统短期负荷预测模型, 并通过算例验证了该模型的可行性, 同时针对影响负荷的气象因素修正了预测结果, 提高了预测的精度。

卡尔曼滤波器在递推过程中不断用新信息对状态估计进行修正, 所以卡尔曼滤波是渐进稳定的, 当时间序列足够长时, 初始状态的状态值、协方差阵对估计的影响都将衰减为零。所以卡尔曼滤波模型能够不断更新状态信息, 获得比较准

确的估计值。

由于卡尔曼滤波结果的最优性建立在确切的模型和准确的噪声协方差的基础之上, 且噪声协方差的精确度与滤波效果密切相关。实际运用中根据已知信息很难准确获得先验的噪声协方差, 针对每个实例都需要手动调试以增强预测精确性, 且模型在运行过程中存在的扰动也会造成定常噪声下的卡尔曼滤波在负荷波动较大时刻精度不高的情况。所以卡尔曼滤波应用于负荷预测中的自适应性有待提高, 可以考虑和小波分析、神经网络等方法结合, 以提高预测的精确度。

### 参考文献

- [1] P. A. Mastorocostas, J. B. Theocharis and A. G. Bakirtzis. Fuzzy modeling for short term load forecasting using the orthogonal least squares method[J]. IEEE Transactions on Power Systems, 1999, 14(1): 29-36.
- [2] Amjady N. Short-term hourly load forecasting using time-series modeling with peak load estimation capability[J]. IEEE Transactions on power systems, 2001, 16(3): 498-505.
- [3] Rahman S, Bhatnagar R. An expert system based algorithm for short term load forecast[J]. IEEE Transactions on Power Systems, 1988, 3(2): 392-399.
- [4] Chen H, Canizares C A, Singh A. ANN-based short-term load forecasting in electricity markets[C]//2001 IEEE power engineering society winter meeting. Conference proceedings (Cat. No. 01CH37194). IEEE, 2001, 2: 411-415.
- [5] Huelsemann S M. Short and Ultra-short Term Load Forecast by Kalmanfilter and Autocorrelation[A]. Proceedings of the Universities Power Engineering Conference. Edinburgh (UK): 1998. 497-500.
- [6] Al-Hamadi H M, Soliman S A. Short-term electric load forecasting based on Kalman filtering algorithm with moving window weather and load model[J]. Electric power systems research, 2004, 68(1): 47-59.
- [7] 马静波. 电力系统短期负荷预测方法研究[D]. 四川大学, 2005.
- [8] 李明干, 孙健利, 刘沛. 基于卡尔曼滤波的电力系统短期负荷预测[J]. 继电器, 2004(04): 9-12.

